Übungsaufgaben II, SBV1

Lukas Fiel, Lisa Panholzerl

November 19, 2018

2 Übungsaufgaben II

2.1 Resampling und Interpolation

a) Implementierung Resampling

Die Implementierung des Resampling Filters wurde in diesem Abschnitt anhand der Nearest Neighbour Interpolation umgesetzt. Bevor der Filter ausgeführt wird, wird zuerst der Skalierungsfaktor bei dem Benutzer abgefragt. Gibt der Benutzer einen Wert ein, der über 1.0 liegt, wird das Bild vergrößert. Gibt er einen Wert ein, der unter 1.0 liegt wird das Eingangsbild verkleinert.

In dieser Implementierung wird die Umrechnung der Koordinaten anhand der Variante B umgesetzt. Dies bedeutet, dass der Skalierungsfaktor bereits vor der Neuberechnung der Koordinaten angepasst wird, in dem von diesem 1 subtrahiert wird. Das heißt, die neue Koordinate vom skalierten Bild B wird mit der Koordinate aus dem Originalbild A um den adaptierten Skalierungsfaktor s' multipliziert. Dies hat zur Folge, dass sich die Indizes in der Mitte zentrieren. Der Anfang bzw. das Ende des Bild Arrays bleibt hierbei aber weiterhin unterrepräsentiert.

; columns

```
import ij.*;
import ij.plugin.filter.PlugInFilter;
import ij.process.*;

import java.awt.*;

import ij.gui.GenericDialog;


public class Resample_ implements PlugInFilter {

   public int setup(String arg, ImagePlus imp) {
                if (arg.equals("about"))
                        {showAbout(); return DONE;}
                return DOES_8G+DOES_STACKS+SUPPORTS_MASKING;
        } //setup



        public void run(ImageProcessor ip) {
                byte[] pixels = (byte[])ip.getPixels();
                int width = ip.getWidth();
                int height = ip.getHeight();
                int tgtRadius = 4;

                int newWidth = width;
                int newHeight = height;

                int[][] inDataArrInt = ImageJUtility.convertFrom1DByteArr(pixels, width,
                    ↪  height);

                //first request target scale factor from user
                GenericDialog dialog = new GenericDialog("user_input");
                dialog.addNumericField("scale_factor:_", 1.0, 2);
                dialog.showDialog();
```

```
        if(dialog.wasCanceled()) {
                return;
        }

        double tgtScaleFactor = dialog.getNextNumber();
        if(tgtScaleFactor < 0.01 || tgtScaleFactor > 10) {
                return;
        }

        newWidth = (int)(width * tgtScaleFactor + 0.5);
        newHeight = (int)(height * tgtScaleFactor + 0.5);


        // variant A of transformation of coordinates
        //double scaleFactorX = newWidth / (double)(width);
        //double scaleFactorY = newHeight / (double)(height);

        // variant B of transformation of coordinates
        double scaleFactorX = (double)(newWidth - 1.0) / (double)(width - 1.0);
        double scaleFactorY = (double)(newHeight - 1.0) / (double)(height - 1.0)
            ↪ ;

        //information output
        System.out.println("tgtScale: " + tgtScaleFactor + ", sX: " +
            ↪ scaleFactorX + ", sY: " + scaleFactorY);
        System.out.println("new width: " + newWidth + ", new height: " +
            ↪ newHeight);

        int[][] scaledImage = new int[newWidth][newHeight];

        //iterate over all pixel of the scaled image
        for(int x = 0; x < newWidth; x++) {
                for (int y = 0 ; y < newHeight; y++) {
                        //calculate new scaled x and y coordinates
                        double newX = (double)(x) / scaleFactorX;
                        double newY = (double)(y) / scaleFactorY;

                        //calculate new result value
                        int resultVal = GetNNinterpolatedValue(inDataArrInt,
                            ↪ newX, newY, width, height);

                        //set new value
                        scaledImage[x][y] = resultVal;

                }
        }

        //show new image
ImageJUtility.showNewImage(scaledImage, newWidth, newHeight, "scaled img");

} //run

void showAbout() {
        IJ.showMessage("About Template ...",
                "this is a PluginFilter template\n");
} //showAbout


public int GetNNinterpolatedValue(int[][] inImg, double x, double y, int width,
    ↪ int height) {
        //round x and y position
        int xPos = (int) (x + 0.5);
        int yPos = (int) (y + 0.5);

        //safety check
        if(xPos >= 0 && xPos < width && yPos >= 0 && yPos < height) {
                return inImg[xPos][yPos];
        }
        return 0;
}

public int GetBilinearinterpolatedValue(int[][] inImg, double x, double y, int
    ↪ width, int height) {
        //implemented in separate java file

}
```

```
} //class Resample_
```

b) Implementierung Bi-Lineare Interpolation

Die Implementierung des Resamplings Filters wurde in diesem Abschnitt anhand der Bilinearen Interpolation umgesetzt. Bevor der Filter ausgeführt wird, wird zuerst der Skalierungsfaktor bei dem Benutzer abgefragt. Gibt der Benutzer einen positiven Wert ein, der über 1.0 liegt, wird das Bild vergrößert. Gibt er einen darunterliegenden Wert ein wird das Eingangsbild verkleinert.

Danach wird die neue Höhe und Breite des Eingangsbildes anhand des Skalierungsfaktor berechnet. Zusätzlich wird der Skalierungsfaktor für die x und y Koordinaten separat berechnet und gespeichert. Anschließend wird anhand einer for-Schleife über alle Pixel des neu angelegten Arrays des skalierten Bildes iteriert.

Neben der neuen Koordinate wird der Pixelwert anhand der Methode GetBilinearInterpolatedValue() berechnet. In dieser werden unterschiedliche Fragemente für die Berechnung des gewichteten Mittelwert aufbereitet. Damit der neue skalare Wert berechnet werden kann, müssen zuerst 4 benachbarten Pixel aus dem Originalbild ermittelt werden. Die Nachbarpixel sind folgende: p1(x+1,y), p2(x,y+t1), p3(x+1, y+1) und p4(x,y).

Um den gewichtet Mittelwert für diesen Pixel zu erhalten werden anhand der Kalkulationsfragmente, den benachbarten skalaren Werten (p1-p4) der gewichtete Mittelwert berechnet werden. Anschließend wird dieser Wert an die Methode retourniert und im skalierten Bild an der aktuellen Koordinate eingefügt.

Test der Implementierung

Um die Implementierung des Resampling Filters anhand der bi-linearen Interpolation zu prüfen, wurden zwei Testbilder inklusive Differenzbilder generiert.

Folgendes Bild wurde um den Faktor 3.0 vergrößert:

Figure 1: Skalierung anhand Faktor 3.0

TODO: Testbild einfügen
TODO: Differenzbild einfügen (Image J Funktionalität)
TODO: Unterschied in skalare Werte, woher?

; columns

```
import ij.*;
import ij.plugin.filter.PlugInFilter;
import ij.process.*;

import ij.gui.GenericDialog;

public class ResampleBilineareInterpolation_ implements PlugInFilter {

        public int setup(String arg, ImagePlus imp) {
                if (arg.equals("about")) {
                        showAbout();
                        return DONE;
```

```
        }
        return DOES_8G + DOES_STACKS + SUPPORTS_MASKING;
    } // setup

    public void run(ImageProcessor ip) {
        byte[] pixels = (byte[]) ip.getPixels();
        int width = ip.getWidth();
        int height = ip.getHeight();

        int[][] inDataArrInt = ImageJUtility.convertFrom1DByteArr(pixels, width,
            ↪ height);

        int newWidth = width;
        int newHeight = height;

        // first request target scale factor from user
        GenericDialog dialog = new GenericDialog("user input");
        dialog.addNumericField("scale factor", 1.0, 2);
        dialog.showDialog();

        // if user has canceled the dialog
        if (dialog.wasCanceled()) {
            return;
        }

        //get user input of scale factor
        double tgtScaleFactor = dialog.getNextNumber();

        // check range
        if (tgtScaleFactor < 0.01 || tgtScaleFactor > 10) {
            return;
        }

        //calculate new width and height with scale factor
        newWidth = (int) (width * tgtScaleFactor + 0.5);
        newHeight = (int) (height * tgtScaleFactor + 0.5);

        // calculate scale factor per dimension (variant a)
        double scaleFactorX = newWidth / ((double) width);
        double scaleFactorY = newHeight / ((double) height);

        //information output
        System.out.println("tgtScale = " + tgtScaleFactor + "sX=" + scaleFactorX
            ↪ + "sY=" + scaleFactorY);
        System.out.println("new width = " + newWidth + "new height = " +
            ↪ newHeight);

        int[][] scaledImg = new int[newWidth][newHeight];

        // fill new result image --> iterate over result image
        for (int x = 0; x < newWidth; x++) {
            for (int y = 0; y < newHeight; y++) {
                // calculate new coordinate
                double newX = x / scaleFactorX;
                double newY = y / scaleFactorY;

                //get bilinear interpolated value
                double resultVal = GetBilinearInterpolatedValue(
                    ↪ inDataArrInt, newX, newY, width, height);

                //set new rounded value for current location
                scaledImg[x][y] = (int) (resultVal + 0.5);

            }
        }

        //show new image
        ImageJUtility.showNewImage(scaledImg, newWidth, newHeight, "scaled img (
            ↪ bilinear interpolation");

    } // run

    public double GetBilinearInterpolatedValue(int[][] inImg, double x, double y,
        ↪ int width, int height) {

        // calculate the delta for x and y
        double deltaX = x - Math.floor(x);
```

```
                double deltaY = y - Math.floor(y);

                // set calculation fregment
                int xPlus1 = (int) x + 1;
                int yPlus1 = (int) y + 1;

                //handling of image edge for x
                if (x + 1 >= width) {
                        xPlus1 = (int) x;
                }

                //handling of image edge for y
                if (y + 1 >= height) {
                        yPlus1 = (int) y;
                }

                // get 4 neighboring pixels
                int neighbor1 = inImg[xPlus1][(int) (y)];
                int neighbor2 = inImg[(int) (x)][yPlus1];
                int neighbor3 = inImg[xPlus1][yPlus1];
                int neighbor4 = inImg[(int) (x)][(int) (y)];

                // calculate weighted mean out of neighbors
                double weightedMean = ((1 - deltaX) * (1 - deltaY) * neighbor4) + (
                    ↪ deltaX * (1 - deltaY) * neighbor1)
                                + ((1 - deltaX) * deltaY * neighbor2) + (deltaX * deltaY
                                    ↪  * neighbor3);

                return weightedMean;
        }

        void showAbout() {
                IJ.showMessage("About Template ...", "this is a PluginFilter template\n"
                    ↪ );
        } // showAbout

} // class ResampleBilinearInterpolation
```

c) Implementierung Checker-Board

TODO: Charakterisierung der beiden Interpolationsstrategien auf Laufzeit und erzielbare Qualität

NN = einfacherer Algorythmus –¿ kürzere Laufzeit BIP = kompolexerer Algorythmus –¿ längerer Laufzeit

NN –¿ kantigeres Ergebnis, da keine Neuberechnung des skalaren Wert stattfindet, sondern eine neue Zuweisung BIP –¿ weicheres Ergebnis, da der skalare Wert aus den 4 Nachbarn und dem Delta berechnet wird

2.2 Klassifizierung mittels Kompression

a) Klassifizierung von Texten

Idee

Aus Texten in 8 verschiedenen Sprachen soll mittels Kompression eine Klassifizierung stattfinden. Dazu wurden folgende Datensätze als ̈*.txt Dätein vorbereitet:

- Abstract einer wissenschaftlichen Arbeit. Diese hatte den Vorteil dass es eine deutsche und englische Übersetzung gab. Alle weiteren Sprachen wurden aus der englischen Version mittels *google translate* generiert.
- Wörterbuch mit 10000 deutschen Wörtern. Dieser Datensatz wurde mittels *google translate* in alle anderen Sprachen übersetzt.
- Die erste Seite der Datenschutzrichtlinien von Facebook. Da die Datenschutzrichtlinien in sämtlichen Sprachen abrufbar sind, konnte für alle Sprachen ein passender Datensatz gefunden werden.
- Die erste Seite der Datenschutzrichtlinien von Google. Auch hier waren Daten in allen Sprachen verfügbar.
- Ein Witz der aus dem deutschen mittels *google translate* in alle andern Sprachen übersetzt wurde.

Da nach einer Übersetzung die Texte in verschiedenen Sprachen ungleich viele Buchstaben beinhalten ist auch die Dateigröße unterschiedlich. Dies könnte eventuell rechnerisch berücksichtigt werden. Viel einfacher aber ist es, die letzten Buchstaben jedes langen Textes zu ignorieren und so eine einheitliche Länge des Textes zu gewährleisten. Dies wurde mittels eines shell-Skripts erreicht, welches nur die ersten n Bytes eines Files speichert. So konnte für jeden Text eine Datei erzeugt werden die in allen Sprachen den selben Speicherbedarf hat. Der Verlust der letzten Byte ist bei einer Klassifizierung unwesentlich.

; columns

```
#!/bin/bash


# mkdir cutTestData
mkdir cutTestData/witzData/

for filename in TestData/witzData/*.txt; do
    dd bs=1 count=8200 if="$filename" of="cut$filename"

done
```

Nach einer solchen Normierung der Texte können diese miteinander verglichen werden. Dazu wurde ein Programm in *Octave* geschrieben (siehe Listing a) , welches die Texte der einzelnen Datensätze miteinander vergleicht und in einer Matrix darstellt. Eine qualitativ hochwertige Aussage ob die Ergebisse statistische Aussagekraft haben, kann mit 5 Datensätzen nicht getroffen werden. Es ist aber sicherlich ein Trend erkennbar.

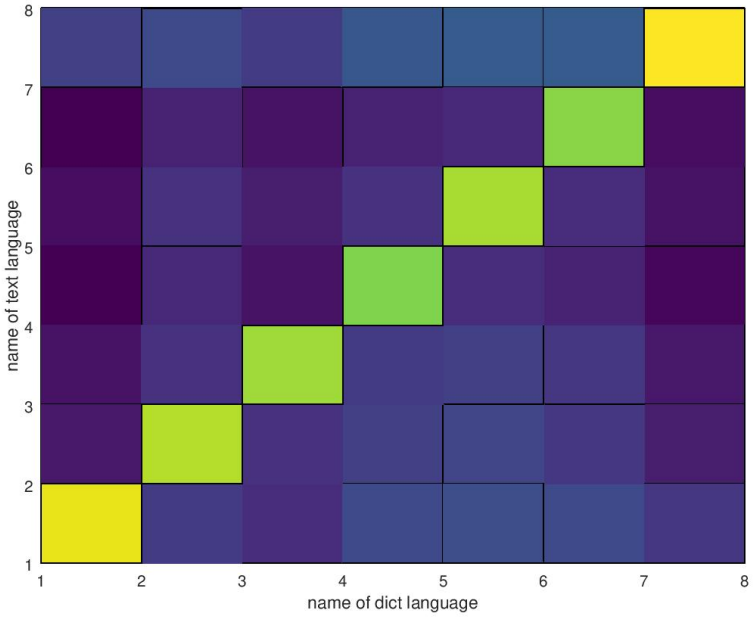

Figure 2: zipDataMatrix

Listing 1: Octave Script zur Darstellung der einzelnen Kompressionsraten.

```
    ; columns

# clear console, clear variables, close all open figures
clc
clear all
close all

# in this example we will use following languages
# languages = {"de","en","fr","es","po","un","bo","ne"};

# constants
# please note:copy-pasting windows paths: there are no backslashes in the path
folderPath = 'cutTestData/*';

# initialize result matrix
resultMatrix =zeros(8);


# loop through data folders
folders = glob(folderPath)
for x=1:numel(folders)
  [~, nameI] = fileparts (folders{x})
  for y=1:numel(folders)
    [~, nameI] = fileparts (folders{y})

    # just calculate matrix for different data sets
    if (!strcmp(folders{x},folders{y}))

      folderPath1 = [folders{x} , '/*'];
      folderPath2 = [folders{y} , '/*'];
      filesOfFolder1 = glob(folderPath1);
      filesOfFolder2 = glob(folderPath2);

      # for every element in data folder
      for i=1:numel(filesOfFolder1)
        [~, nameI] = fileparts (filesOfFolder1{i});
        #get file size
        [info, err, msg] = stat (filesOfFolder1{i});
        file1Size = info.size;

        #CREATE zip of file
        tmpFolderPath = nameI;
        mkdir(tmpFolderPath);
        copyfile(filesOfFolder1{i},tmpFolderPath);
        firstZipName = [nameI, '.zip']
        zip(firstZipName,[tmpFolderPath,'/*']);
        #get zip size
        [info, err, msg] = stat (firstZipName);
        file1file2ZipSize = info.size;

        # calculate compression rate
        file1CompressionRate = file1file2ZipSize / file1Size;

        #delete zip and folder as we just need the size for calculation
        delete([tmpFolderPath,'/',nameI,'.txt']);
        rmdir(tmpFolderPath);
        delete(firstZipName);

        for j=1:numel(filesOfFolder2)
          [~, nameJ] = fileparts (filesOfFolder2{j});
          zipName = [nameI,nameJ,'.zip'];
          #create tmp folder in testData folder
          tmpFolderPath = [nameI,nameJ];
          mkdir(tmpFolderPath);

          #copy filesOfFolder1 to folder
          ['copy filesOfFolder1 ', nameI, ' , ' nameJ , ' to ' , tmpFolderPath];
          copyfile(filesOfFolder1{i},tmpFolderPath);
          copyfile(filesOfFolder2{j},tmpFolderPath);

          # get folder size (add jokeFile size to filesOfFolder1ize)
          [info, err, msg] = stat (filesOfFolder2{i});
          file2Size = file1Size + info.size;

          #zip it and get size of zip
          zip(zipName,[tmpFolderPath,'/*']);
```

```
          [info, err, msg] = stat (zipName);
          file2ZipSize = info.size;

          #calculate compression rate
          compressionRate = file2ZipSize / file2Size ;

          #calculate exprected rate
          expectedfile2ZipSize = file2Size * file1CompressionRate;

          %Matrix(i,j) = (expectedfile2ZipSize - file2ZipSize) /  file2ZipSize;
          kompressionDict = (file1Size -file1file2ZipSize) / file1Size;
          kompressionBoth = (file2Size - file2ZipSize) / file2Size;
          kompressionsDelta = abs(kompressionBoth - kompressionDict);
          Matrix(i,j) = kompressionsDelta;


          #cleanup - remove tmp folder
          ['remove ' tmpFolderPath];
          delete([tmpFolderPath,'/',nameI,'.txt']);
          delete([tmpFolderPath,'/',nameJ,'.txt']);
          rmdir(tmpFolderPath);
          delete(zipName);
        endfor
      endfor

      resultMatrix = resultMatrix .+ Matrix;

    else # dont calculate anything if the folders are the same
      ["skip " folders{x}]
    endif


  endfor
endfor

    figure()
    surf(resultMatrix)
    view(2)
    xlabel("name of dict language");
    ylabel("name of text language");
    zlabel(" diff of compression rates");
    'SUCCESS'
```

b) OPTIONAL – nur für Interessierte/Experten

2.3 Kompression und Code-Transformation

a) Lempel-Ziv Kompression einer Sequenz

Figure a) zeigt die händische Berechnung der Lemper Ziv Kompression. Beim Übertragen ins Protokoll wurde allerdings ein Fehler entdeckt, der in Tabelle 1 korrigiert wurde.

Aufgabe 2.3.a Lempel Ziv Kompression

Zeichenkette: a b a b a b b b a a a a b a b a b c c d d d a

aktuelles Zeichen	nächstes Zeichen	Ausgabe? im Wörterbuch?		Ins Wörterbuch?	
a	b	N	a	ab	256
b	a	N	b	ba	257
a	b	Y	256	aba	258
~~a~~	b	Y	256	abb	259
b	b	N	b	bb	260
b	a	Y	257	baa	261
a	a	N	a	aa	262
a	a	Y	262	aab	263
a	a	Y	257	bab	264
b	a	Y	257 Y 264	babc	265
c	c	N	c	cc	266
c	d	N	c	cd	267
d	d	N	d	dd	268
d		Y	268	dda	269

23 Zeichen im Ursprungstext
14 Zeichen im Resultat

Zeichenkette:

97, 98, 256, 256, 98, 257, 97, 262, 257, 257, 264, 99, 99,
↳ 100, 268

Kompressionsrate: $\frac{23}{14} = 1,64$

aktuelles Zeichen	nächstes Zeichen	Ausgabe (im Wörterbuch?)	ins Wörterbuch!	Speicher
a	b	N → a	ab	256
b	a	N → b	ba	257
a	b	Y → 256	aba	258
a	b	Y → 256	abb	259
b	b	N → b	bb	260
b	a	Y → 257	baa	261
a	a	N → a	aa	262
a	a	Y → 256	aab	263
b	a	Y → 257	bab	264
b	a	Y (257), Y → 264	babc	265
c	c	N → c	cc	266
c	d	N → c	cd	267
d	d	N → d	dd	268
d	d	Y → 268	dda	269
a		N → a		

Table 1: Level Ziv Kompression

In der korrigierten Version ergibt die resultierende Zeichenkette:

97	98	256	256	98	257	97	262	257	264	99	99	100	268	269

$$[H]KompressionsrateC = \frac{23}{15} = 1.5334 \tag{1}$$

b) Huffmann Coding

Die nächste Seite zeigt die händische Berechnung des Huffmann Baums zum gegebenen Beispiel. Die mittlere Codewortlänge lieght dabei bei $1.869bit$.

Weiters kann man auf der darauffolgenden Seite die manuelle Berechnung von 6 Testfällen finden. Es kann gesagt werden, dass die Huffmann Kompression sehr gut geeignet wäre um Daten zu komprimieren, die sehr oft gleich sind. Dabei spielt homogenität keine Rolle, sondern rein die Häufigkeit des Auftretens der Sonderfälle. An diser Stelle sei erwähbt, dass die Information

über solche Sonderfälle nicht verlohren geht, sondern einfach mehr Speicher benötigt (verlusstfreies Komprimieren)

1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23
a	b	a	b	a	b	b	b	a	a	a	a	b	a	b	a	b	c	c	d	d	d	a

codierung $a = 00,\ b = 01,\ c = 10,\ d = 11$

23 Zeichen zu 2 bit ergeben eine Länge von 46 bit

Häufigkeiten

a: 10	$10/23 = 0{,}435$	} sort {	a	1	1
b: 8	$8/23 = 0{,}348$		b	01	2
c: 2	$2/23 = 0{,}087$		c	000	4
d: 3	$3/23 = 0{,}130$		d	001	3

Baum

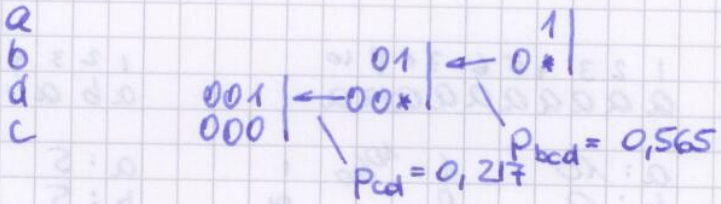

mittlere Codewortlänge

$$L = 1 \cdot 10 + 2 \cdot 0{,}348 + 3 \cdot 0{,}087 + 3 \cdot 0{,}130 = 1{,}782 \text{ bit}$$

Kompressionsrate $\frac{2 \text{ bit}}{1{,}782 \text{ bit}} = 1{,}122$

Binärlayout: $10 \cdot 1 + 8 \cdot 2 + 2 \cdot 3 + 3 \cdot 3 = 41$ bit

Zeichen: {a, b, c, d} → 2bit Darstellung {00, 01, 10, 11}

1 2 3 4 5 6 7 8 9 10
a b c d a b c d a b

a: 3	$3/10 = 0,3$	1
b: 3	$3/10 = 0,3$	01
c: 2	$2/10 = 0,2$	001
d: 2	$2/10 = 0,2$	000

$L = 1 \cdot 0,3 + 2 \cdot 0,3 + 3 \cdot 0,2 \cdot 2$
$= 2,1$

Kompressionsrate: 0,95
→ keine Kompression

1 2 3 4 5 6 7 8 9 10
a a a a a a a b c d

a: 7	$7/10 = 0,7$	1
b: 1	$1/10 = 0,1$	01
c: 1	$1/10 = 0,1$	001
d: 1	$1/10 = 0,1$	000

$L = 1 \cdot 0,7 + 2 \cdot 0,1 + 3 \cdot 0,1 \cdot 2$
$= 1,5$

Kompressionsrate: ~~1,5~~ 1,3

1 2 3 4 5 6 7 8 9 10
a a a a a a a a a a

a: 10	$1 = 10/10$	1
b: 0	0	01
c: 0	0	001
d: 0	0	000

$L = 1 \cdot 1 + 2 \cdot 0 + 3 \cdot 0 \cdot 2$
$= 1$

Kompressionsrate: 2

1 2 3 4 5 6 7 8 9 10
a b a b a b a b a b

a: 5	$5/10 = 0,5$	1
b: 5	$5/10 = 0,5$	01
c: 0	0	001
d: 0	0	000

$L = 1 \cdot 0,5 + 2 \cdot 0,5 + 3 \cdot 0$
$= 1,5$

Kompressionsrate: 1,3

1 2 3 4 5 6 7 8 9 10
b b b b b c b b b b

a: 0	0	000
b: 9	$9/10 = 0,9$	1
c: 1	$1/10 = 0,1$	01
d: 0	0	001

$L = 1 \cdot 0,9 + 2 \cdot 0,1 + 3 \cdot 0 \cdot 2$
$= 1,1$

Kompressionsrate: 1,82

1 2 3 4 5 6 7 8 9 10
c d c d c d c d c d

a: 0	0	000
b: 0	0	001
c: 5	$5/10 = 0,5$	01
d: 5	$5/10 = 0,5$	1

$L = 1 \cdot 0,5 + 2 \cdot 0,5 + 3 \cdot 0 = 1,5$

Kompressionsrate: 1,3

c) Komprimierung einer Sequenz mittels Runlength Coding

Berechnung der Kompressionsrate

Die nachfolgende Sequenz soll anhand von Runlength Coding händisch komprimiert und die Kompressionsrate ausgegeben werden:

0101011111000001111000101011111 (30 Stellen, n=2 Symbole:0,1)

Die Sequenz wird von links nach rechts codiert, und anstatt der eigentlichen Zeichen die Häufigkeit dieser ausgegeben. Nach der händischen Komprimierung weist die Frequenz folgende Lauflänge auf:

11111554311114 (14 Stellen)

Daraus ergibt sich folgende Kompressionsrate:

30/14 = **2,14**

Erweiterung der Symbolmenge

Die Komprimierung von Sequenzen anhand der RLC ist am effektivsten, je homogener der Informationsgehalt ist. Das bedeutet, das bei vielen unterschiedlichen Zeichen die Komprimierungsmethode nicht mehr sinnvoll angewandt werden kann. Bei sehr kurzen Sequenzen kann es sogar zu einer Erhöhung der Zeichenanzahl in dieser kommen.

Wird nun die Anzahl der Symbole erhöht, muss beachtet werden, dass zusätzlich zu der Häufigkeit des Zeichens noch ein Trennsymbol, eine ID bzw. das Zeichen selbst mitgegeben werden muss. Dies wird anhand eines selbst gewählten Beispiels demonstriert.

Folgende Sequenz wird anhand von RLC komprimiert:

AABBBBBBBBCCCCCCCDEEEEEEEFFGHIIJJJKLMNNN
(40 Stellen, n=13 Symbole:A,B,C,D,E,F,G,H,I,J,K,L,M,N)

Die komprimierte Sequenz lautet:

A2B8C7D1E7F2H1I2J3K1L1M1N3 (26 Stellen)

Daraus ergibt sich folgende Kompressionsrate:

40/26=**1,54**

Wird eine sehr kurze Sequenz mit einer hohen Anzahl an Symbolen komprimiert, kann es aufgrund des hohen Informationsgehalts dazu kommen, dass die codierte Sequenz länger ist, als die Originale.

Folgende Sequenz wird anhand von RLC komprimiert:
ABBCDEEFFFGHIIJJJKLLLMNOPQRSTU
(30 Stellen, n=21 Symbole:A,B,C,D,E,F,G,H,I,J,K,L,M,N,O,P,Q,R,S,T,U)

Die komprimierte Sequenz lautet:
A1B2C1D1E2F3G1H1I2J3K1L3M1N1O1P1Q1R1S1T1U1 (42 Stellen)

Daraus ergibt sich folgende Kompressionsrate:
30/42=**0,71**

d) Entropieberechnung

Folgende Sequenz zur Entropieberechnung ist gegeben:
111122661112233334564511211111 (30 Stellen, n=6 Symbole: 1,2,3,4,5,6)

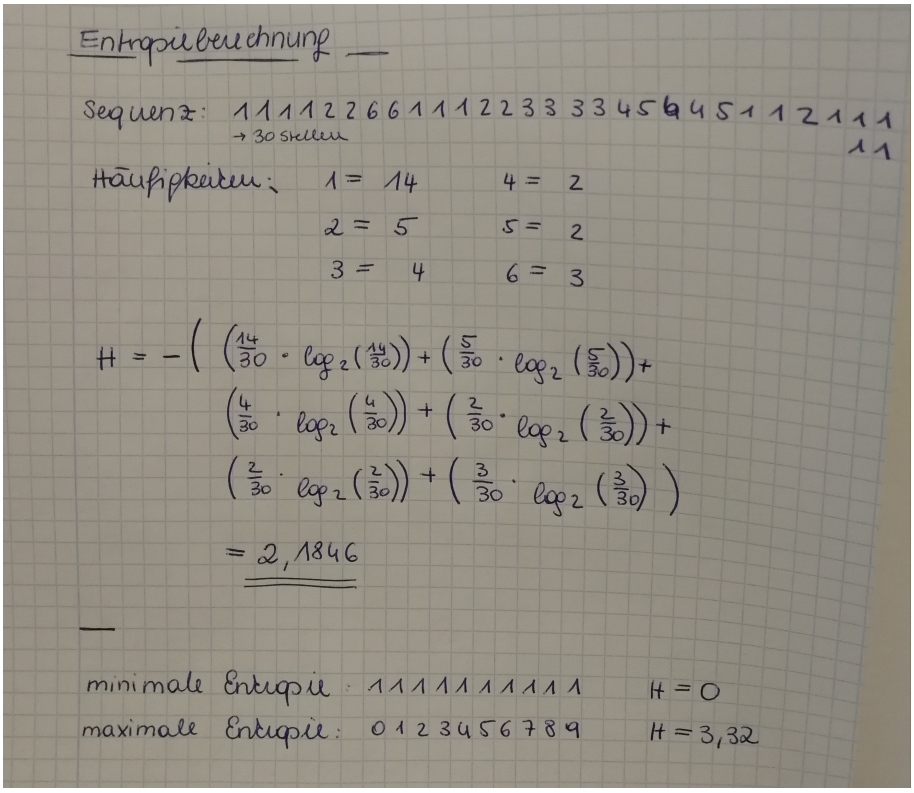

Figure 3: manuelle Entropieberechnung

Nachdem die Häufigkeiten der Symbole erfasst wurde, wurde die Formel der Shannon-Entropie angewandt. Das Ergebnis der Berechnung lautet **2,1846**.

Minimale und Maximale Entropie
Bei foglender 10-stelliger Sequenz ist die Entropie minimal:
Sequenz: 1111111111 (10 Stellen, n=1 Symbol: 1)
H = 0

Bei folgender 10-stelliger Sequenz ist die Entropie maximal:
Sequenz: 0123456789 (10 Stellen, n=10 Symbole: 0,1,2,3,4,5,6,7,8,9)
H = 3,32

Auswirkung auf Kompressionsrate

Eine geringe Entropie bewirkt, dass die Sequenz besser komprimierbar ist. Je höher die Entropie, desto schlechter ist die Sequenz komprimierbar. Nicht nur die Auftrittswahrscheinlichkeit hat eine Auswirkung auf die erzielbare Kompressionsrate. Auch die Länge der Sequenz, sowie die Anzahl der Zeichen spielt eine wesentliche Rolle. Je größer diese Faktoren, desto schlechter ist eine Sequenz durch unterschiedliche Kompressionsverfahren bearbeitbar.